

智谱共融：KG+LLM协同

大模型驱动的知识图谱
范式重构与演化路径

演讲人：王昊奋 | 同济大学 特聘研究员

DataFunSummit 2025



目 录

C O N T E N T S

DataFunSummit 2025

01 | KG+LLM概述

KG+LLM的特点与必要性

02 | KG+LLM的深度融合

如何结合KG增强LLM推理能力

03 | 应用与展望

KG+LLM的行业应用与趋势展望

KG+LLM概述

KG+LLM的特点与必要性

实现数据智能的两种方式

专家系统

数据

- 来源多样
- 形态复杂
- 治理困难

符号知识

- 专家知识隐性，难外化
- 知识体系庞杂，难表示
- 受众小、难获取

智能

- 应用场景复杂
- 推理链条长、相关因素多
- 人机交互要求高

数据转换成符号知识的过程往往伴随着巨大的信息损失
隐性知识、难以表达的知识是损失信息中的主体

统计学习

数据

- 依赖海量高质量标注样本
- 高质量样本缺失是瓶颈
- 人工样本标注代价大

统计模型

- 本质是数据拟合
- “模式内蕴”的任务易于成功
- “背景关联”的任务仍有困难

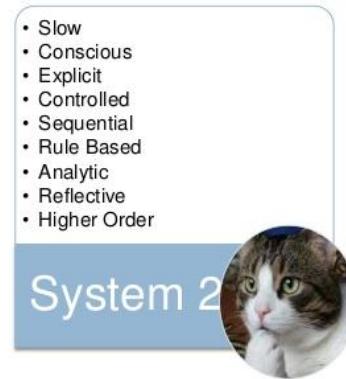
智能

- 迁移能力仍然有限
- 泛化能力是关键
- 分布偏差是困难根源

深度学习的强大的特征提取能力使得“数”尽其用

双系统理论启发

- 双系统理论（Dual Process Theory）认为，人类思维包含两种不同历程：
 - 系统1是快速、直觉、无意识的，负责日常任务和快速决策；
 - 系统2是缓慢、逻辑、有意识的，处理复杂计算和深思熟虑的决策；



数据驱动
(大语言模型)



知识驱动
(知识图谱)

“数”尽其用

可控、可干预、可解释

单一认知方式难以解决问题，双系统的连续交互协作是实现高级认知能力的关键

KG+LLM的必要性

系统1：直觉式、发散性的快速反应



优点：先验知识丰富，泛化性强，
灵活性高；

缺点：推理能力弱，可解释性差，
存在幻觉；

系统2：逻辑性、结构化的深度思考



KGs

优点：结构化表示，可解释性强，
包含符号逻辑；

缺点：知识更新慢，存在数据稀疏
问题，推理效率有限。

神经符号AI系统

缓解幻觉

缓解固有偏见

细化语言处理能力

增强上下文理解能力

增强逻辑推理能力

<https://enterprise-knowledge.com/synergizing-knowledge-graphs-with-large-language-models-llms/>

KG+LLM的深度融合

如何结合KG增强LLM推理能力

如何融合KG增强LLM推理能力？

KG与LLM融合的五大技术路径： 1) Prompt工程 2) 模型微调 3) RAG 4) LRM协同 5) 知识智能体

Prompt工程

图谱增强提示

模型微调

图谱知识注入

RAG

图谱增强检索

LRM协同

检索链规划

知识智能体

图谱优化工作流

图谱推理微调

轻量化GraphRAG

算子/实体规划

图谱知识对齐

个性化GraphRAG

路径搜索

行为预测

图谱增强提示

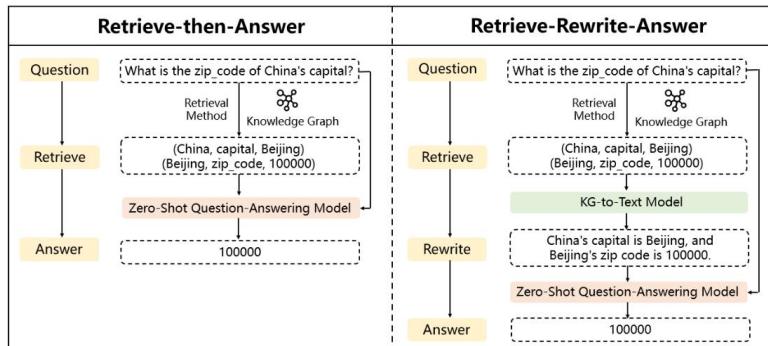
DataFun.

KG-to-Text: 将KG重写为高效的文本表述

KG-to-Text增强框架 (Retrieve-Rewrite-Answer)：在传统检索-回答流程中插入重写模块，将检索到的**三元组重写为文本描述**，强化大语言模型对结构化知识的理解能力。

任务敏感型知识生成：通过答案引导的KG-to-Text机制，**动态筛选与问题最相关的三元组**，并基于微调后的LLM转化成高效的知识文本，解决知识冗余问题。

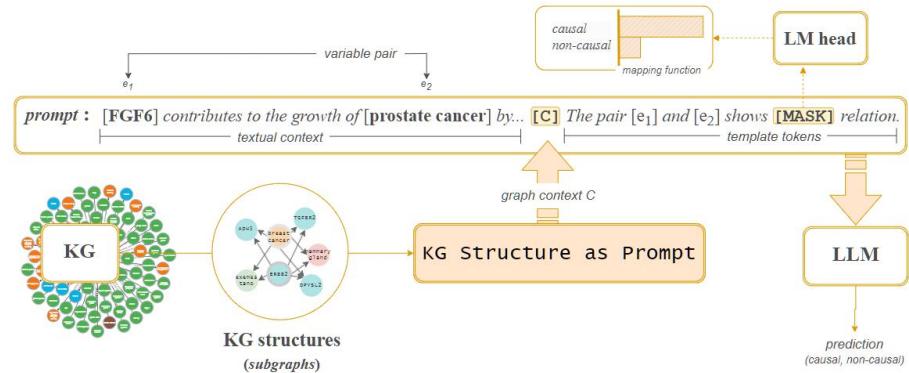
自迭代语料构建策略：利用LLM对生成文本的逻辑校验能力，自动创建图谱-文本对齐语料，解决KGQA任务中标注数据稀缺问题，**实现KG-to-Text模型的闭环训练优化**。



KG Structure as Prompt: 结合图谱结构

知识结构提示融合：通过将**KG拓扑关系编码为提示**，注入小规模语言模型的上下文学习范式，实现文本因果推理任务中背景知识与统计先验的协同建模。

轻量化因果推理引擎：构建基于多领域数据集的三维评估体系，**验证轻量化模型**在结构增强提示下的**因果发现效能**，探索参数效率与知识泛化能力的帕累托最优边界。

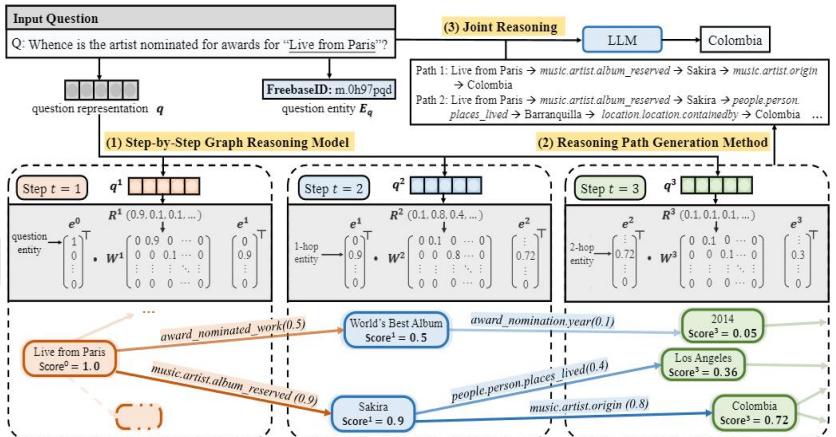


图谱增强提示

KG-to-CoT: 结合图推理模型生成推理链

逐步图推理机制：通过图推理模型，在KG中实现多跳路径遍历与高置信度实体定位，为LLMs注入可解释的知识链

推理路径追溯生成：基于问题实体逆向解析图推理过程，通过转移矩阵回溯生成结构化推理路径，弥合LLMs与知识库的认知鸿沟，支持两者的协同推理能力。

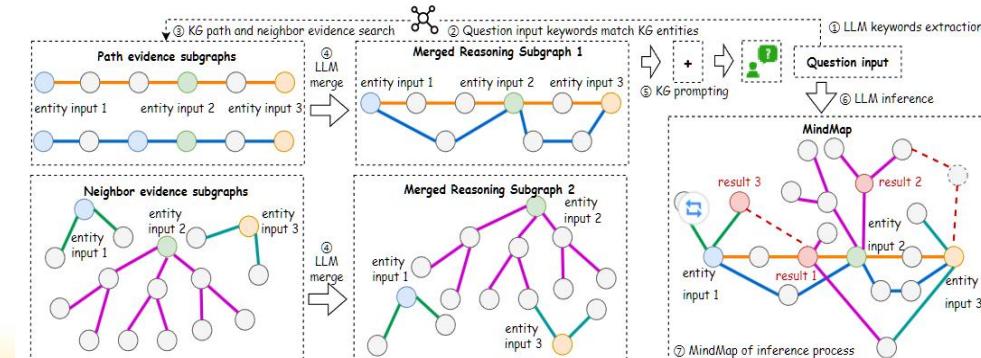


MindMap: 结合KG综合信息

即插即用图提示机制：通过触发LLM的图式思维构建思维导图，动态整合KG显性事实与LLM隐式知识，实现无需参数更新的多跳协同推理，适配预训练大模型及商业API服务；

图结构认知增强：在提示中整合知识图谱拓扑关系，引导LLM解析图模式并自主扩展推理路径，突破传统文本化KG输入的扁平化表征瓶颈，抑制事实幻觉；

多源知识融合推理：基于检索子图与LLM内部知识构建动态思维网络，通过图结构遍历实现显性证据链验证与隐性知识补全的双向协同，生成可解释的联合推理轨迹。



如何融合KG增强LLM推理能力？

KG与LLM融合的五大技术路径：1) Prompt工程 2) 模型微调 3) RAG 4) LRM协同 5) 知识智能体

Prompt工程

模型微调

RAG

LRM协同

知识智能体

图谱增强提示

图谱知识注入

图谱增强检索

检索链规划

图谱优化工作流

图谱推理微调

轻量化GraphRAG

算子/实体规划

图谱个性化智能体

图谱知识对齐

个性化GraphRAG

路径搜索

行为预测

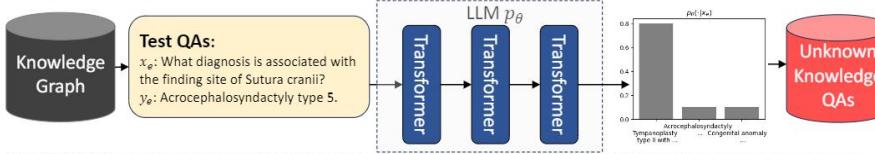
图谱知识注入

InfuserKI: 未知知识注入

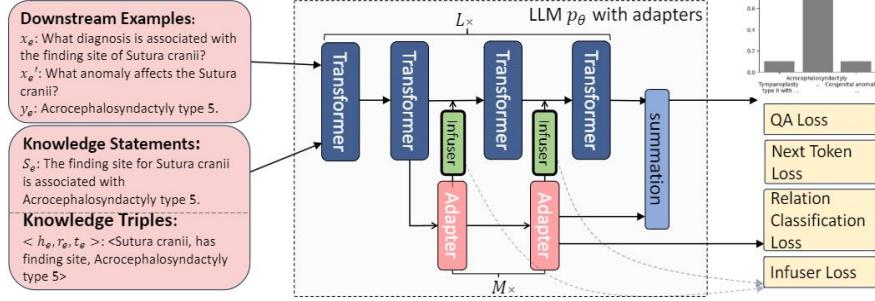
未知知识探测：通过对已知知识和未知知识的**额外知识进行适应性选择**，最大程度地减少了对现有知识的影响并且避免知识遗忘。

新知识融合：在保证LLM原始参数完整的情况下，使用Knowledge Adapter来嵌入新知识。为防止与现有知识的混淆，通过Knowledge Infuser引导，**有效进行知识注入**。

Step 1 Knowledge Detection via Question Answering



Step 2 Knowledge Integration via Infuser-Guided Adapters

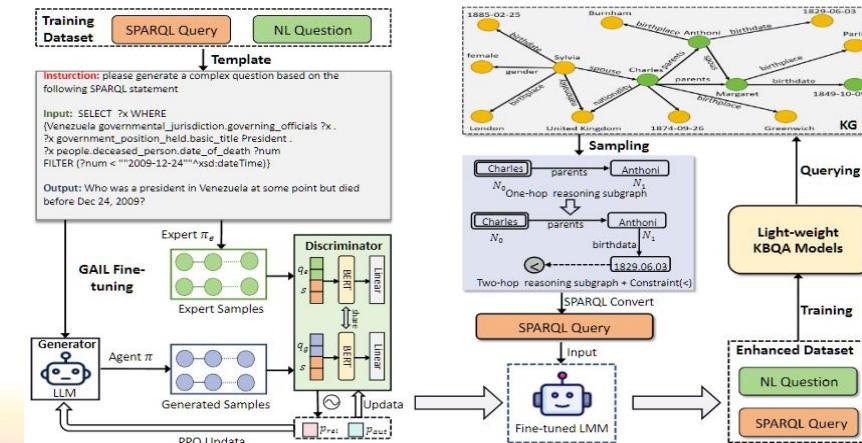


GAIL Fine-tuning: 低资源知识注入

GAIL数据生成：基于GAIL框架与双判别器机制，驱动LLM**生成额外高拟真问题**，结合PPO算法稳定对抗训练过程。

模板化SPARQL扩充：通过自动化算法构建多类型查询模板，**从KG批量采样实例化SPARQL**，保障合成数据多样性与逻辑合理性。

轻量级模型持续增强：将**合成数据注入**轻量KGQA模型训练，实现性能渐进式优化，并部署轻量模型完成推理，兼顾效果与效率。



图谱推理微调

Retrieval & Reason on KG: 提升多跳推理能力

子图推理增强检索：基于思维链构建多跳子图，通过中间推理步骤扩展候选知识语义，辅助**检索关键中间KG事实**。

轻量化KG结构化表征：采用**YAML格式**压缩冗余输入，保留KG内部结构完整性，**提升LLM处理效率**。

KG指令调优三任务：在预训练阶段设计实体预测、关系推断、子图补全任务，**强化LLM对KG三元组和拓扑的理解**。

可解释推理数据蒸馏：借助大规模开源LLM生成逻辑严密的推理过程数据，**训练轻量模型多步推理能力**。

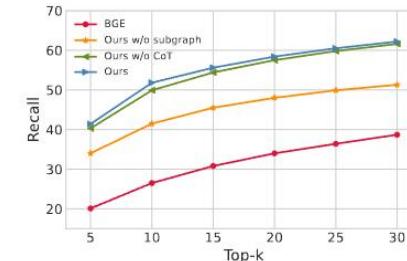
```
(Justin Bieber, profession, Musician),
(Justin Bieber, profession, Record
producer), (Justin Bieber, album, All
Bad), (Justin Bieber, album, Believe
Acoustic),
[... ...]
```

Triple format

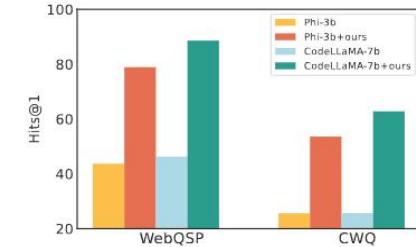
```
Justin Bieber:
profession:
- Musician
- Record producer
album:
- All Bad
- Believe Acoustic
[... ...]
```

YAML format

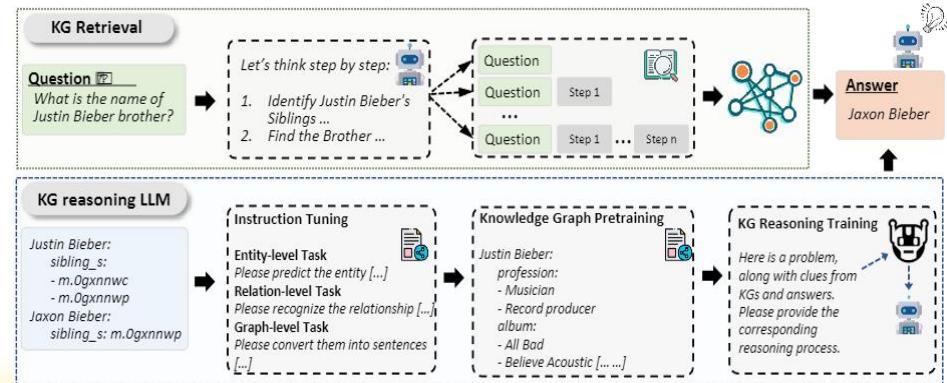
KG输入格式转化示例



子图增强方法的检索
召回率提升20个点



通过微调显著提升LLM
的多跳推理能力

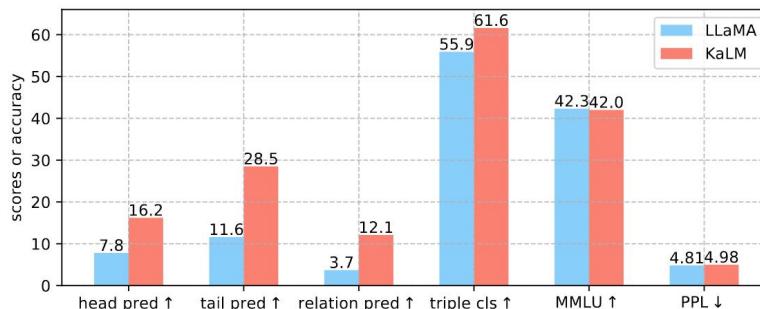


图谱知识对齐

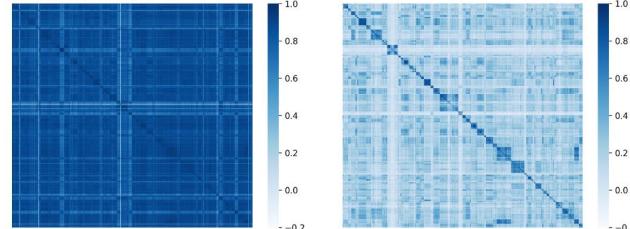
KaLM: 显式与隐式知识对齐

双视图显式知识对齐：通过构建尾实体描述与头实体描述、关系描述的对比学习数据，实现语义对齐，**优化LLMs中显式知识的隐藏表示**。

隐式知识对齐：利用知识图谱三元组构造补全式微调数据集，融合知识推理的文本模式到语言模型微调中，强化指令遵循能力的同时保持生成性能，**促进隐式知识的深度对齐**。



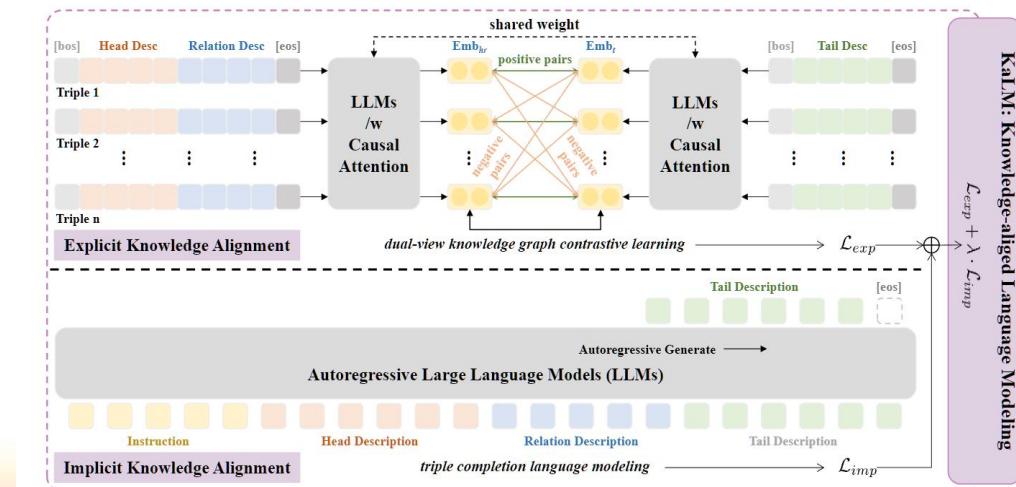
上图展示了微调前后模型在生成式知识推理任务上的表现。通过对齐，KaLM在所有任务上都取得了显著提升



(a) LLaMA

(b) KaLM

上图为微调前后模型的头尾实体的相似度矩阵，通过知识对齐，模型能有效区分头尾实体，实现知识表示的对齐性和一致性。



如何融合KG增强LLM推理能力？

KG与LLM融合的五大技术路径：1) Prompt工程 2) 模型微调 3) RAG 4) LRM协同 5) 知识智能体

Prompt工程

模型微调

RAG

LRM协同

知识智能体

图谱增强提示

图谱知识注入

图谱增强检索

检索链规划

图谱优化工作流

图谱推理微调

轻量化GraphRAG

算子/实体规划

图谱个性化智能体

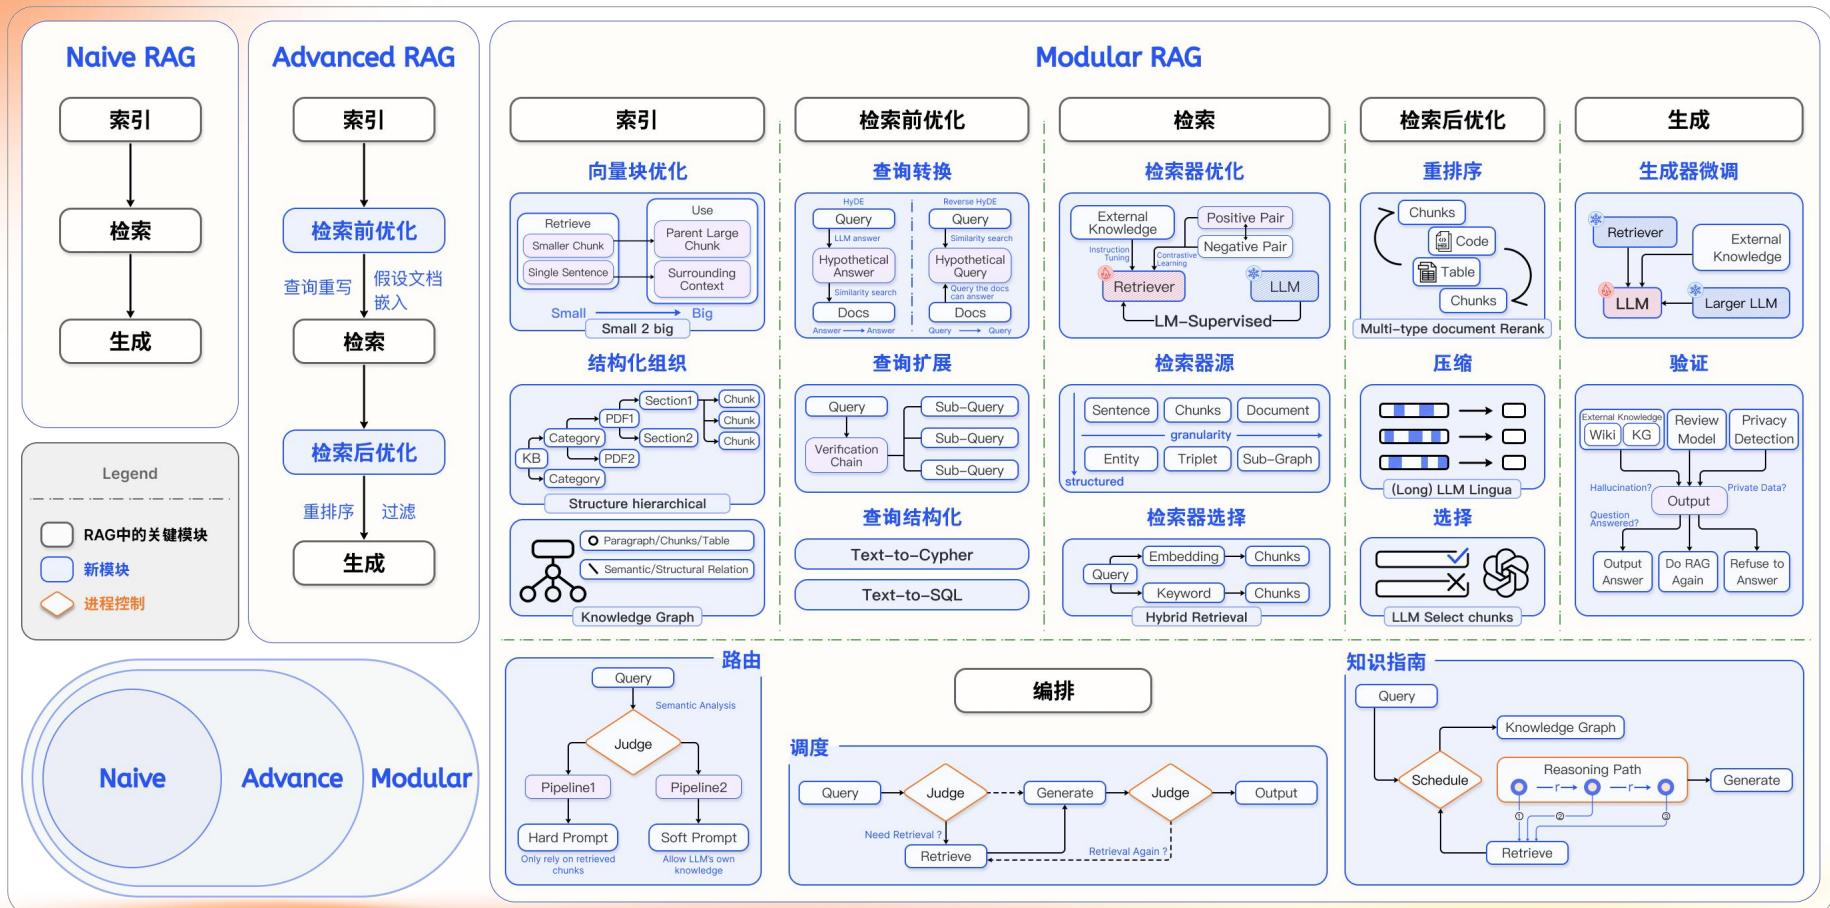
图谱知识对齐

个性化GraphRAG

路径搜索

行为预测

KG+LLM——RAG主要范式

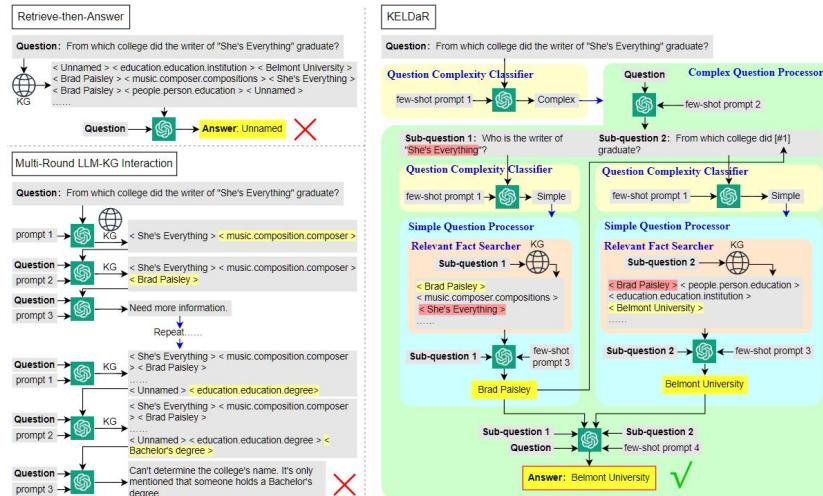


图谱增强检索

KELDaR: 问题分解与原子检索

问题分解树框架：基于问题复杂度分类构建分解树，将**复杂问题拆分为多步推理结构**，各推理步骤可在知识图谱上执行**原子检索**。

高效原子检索策略：通过提取问题相关子图、扩展修剪后的候选子图范围，**优化知识图谱检索效率**，减少冗余信息干扰。

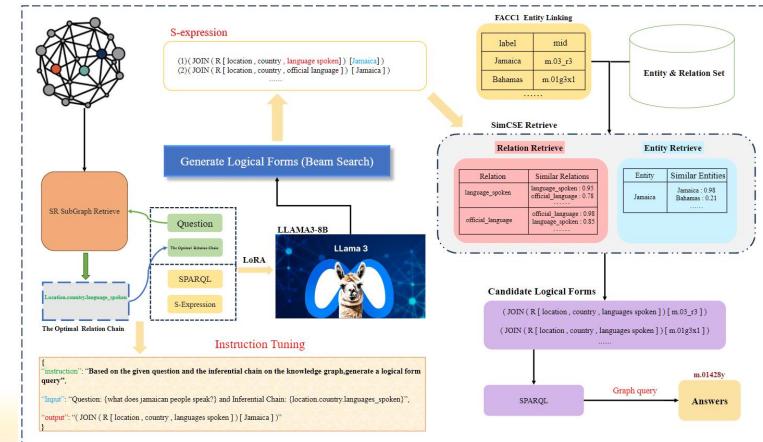


RGR-KBQA: 结合逻辑形式减少幻觉

知识引导的关系链检索：通过检索知识图谱中最相关的关系链，**增强逻辑形式生成的相关性和细粒度**；

微调LLM引导逻辑形式生成：结合KG抽取信息与微调后大模型的隐式知识表征，实现**问题理解与逻辑形式的协同生成**；

无监督短语级语义检索优化生成：基于语义相似度的**短语级检索机制**，在解码阶段动态校准生成结果，**提升逻辑形式的准确性与知识一致性**。



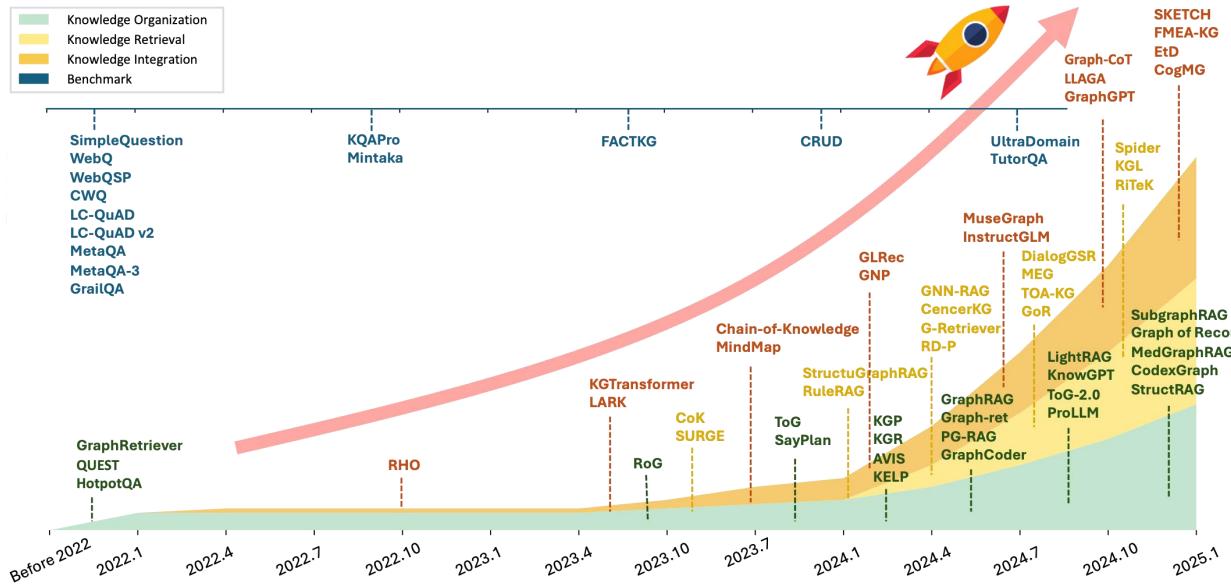
GraphRAG

DataFun.

GraphRAG成为前沿探索方向

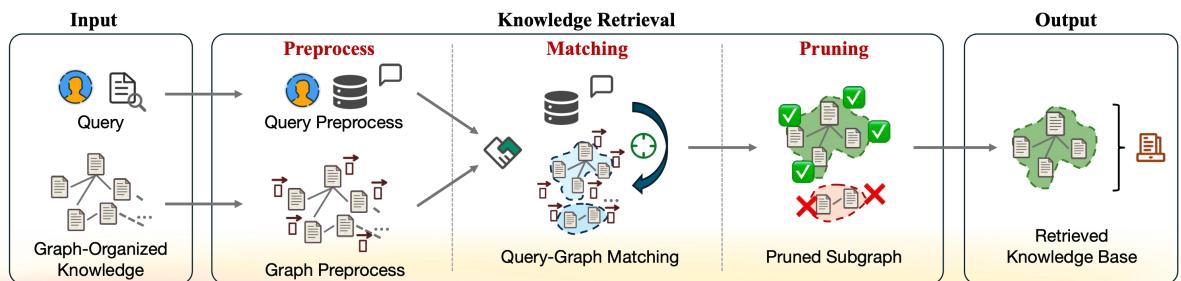
Graph结构的潜在优势

- 更强的复杂推理能力
- 更清晰的可解释可追溯性
- 更好的知识表达与关联性
- 更灵活的知识源集成能力



GraphRAG的核心议题

- 图推理能力增强
- 图结构化的知识表示
- 高效的图信息检索
- 利用图上知识的校验



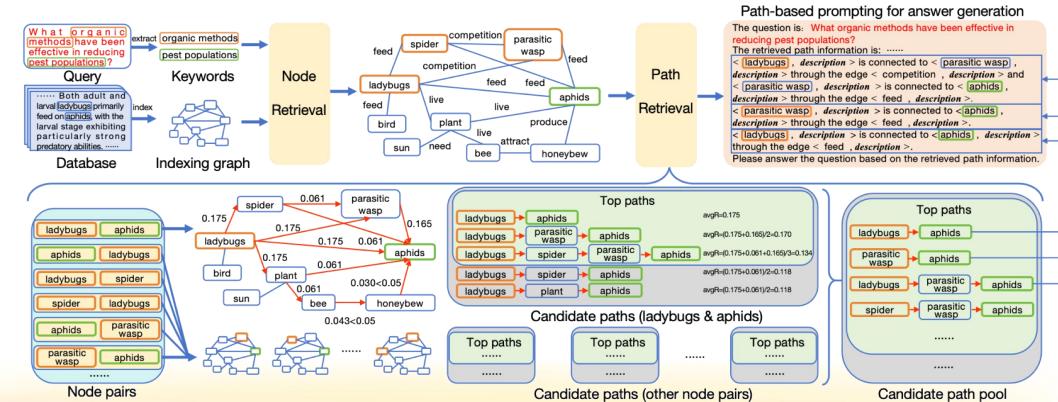
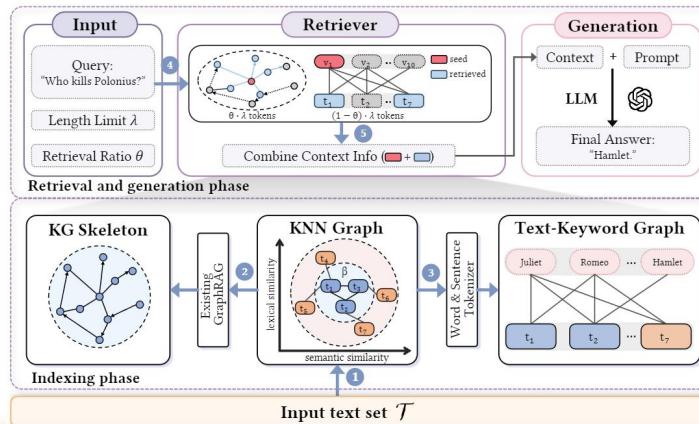
轻量化GraphRAG

KET: 只构建核心图

核心知识图谱骨架构建：基于中间KNN图的中心性筛选核心文本块，利用KG-RAG构建轻量化知识图谱骨架。

轻量文本-关键词二分图补充：建立文本块与关键词的二分关联图，将关键词作为候选实体、共现关系作为知识表征，保留原始文本语义信息，缓解骨架构建导致的信息损失。

双通道检索增强生成：在检索阶段融合知识图谱骨架和二分图的局部子图信息，支撑大语言模型的生成质量优化。



个性化GraphRAG

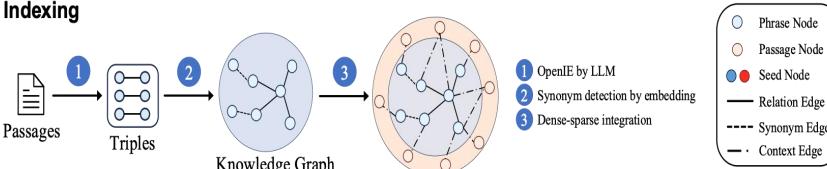
DataFun.

HippoRAG2: 模拟人类长期记忆

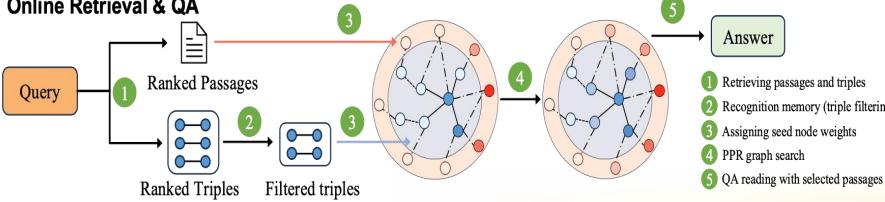
个性化的PageRank: 进行多跳推理, 提升复杂问题的关联性检索能力。

密集-稀疏编码结合: 引入短语节点和段落节点, 模拟人类大脑的密集-稀疏编码机制, 更好地整合概念和上下文。

Offline Indexing



Online Retrieval & QA

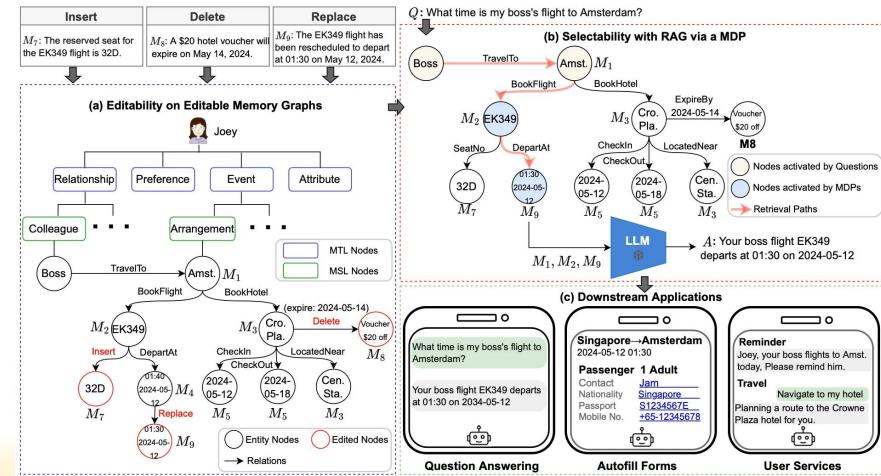


From RAG to Memory: Non-Parametric Continual Learning for Large Language Models, 2025.

EMG-RAG: 个人的记忆构建与利用

可编辑记忆图: 多层数据结构, 记忆类型层、记忆子类层和记忆图层, 支持记忆的插入、删除和替换操作, 能够动态管理个人记忆。

强化学习优化: 学习在图上选择相关记忆, 动态调整记忆选择策略, 以生成更准确的答案, 优化记忆选择过程。



Crafting Personalized Agents through Retrieval-Augmented Generation on Editable Memory Graphs, 2024.

如何融合KG增强LLM推理能力？

KG与LLM融合的五大技术路径：1) Prompt工程 2) 模型微调 3) RAG 4) LRM协同 5) 知识智能体

Prompt工程

模型微调

RAG

LRM协同

知识智能体

图谱增强提示

图谱知识注入

图谱增强检索

检索链规划

图谱优化工作流

图谱推理微调

轻量化GraphRAG

算子/实体规划

图谱个性化智能体

图谱知识对齐

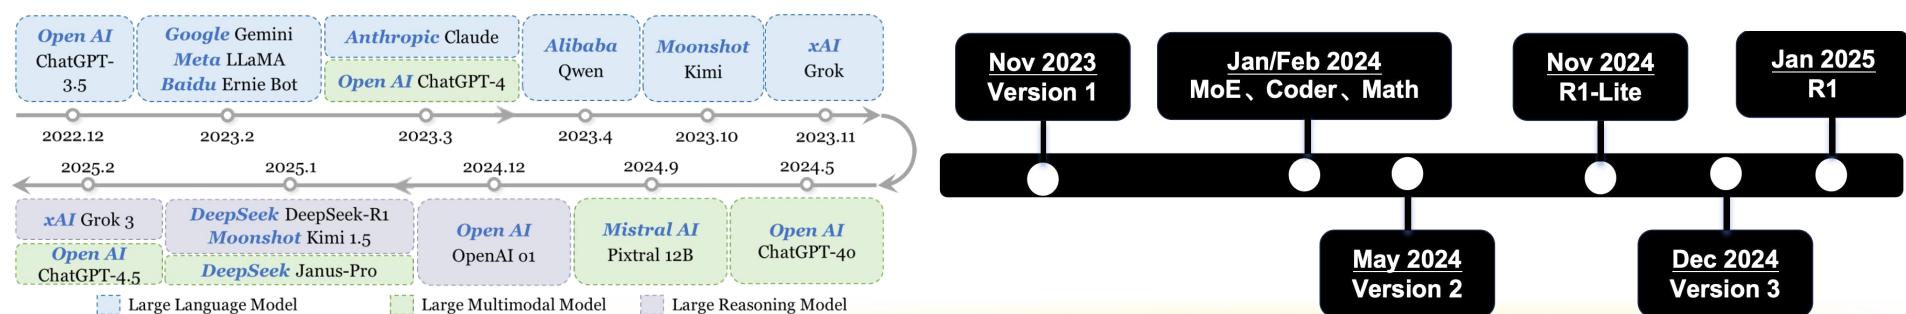
个性化GraphRAG

路径搜索

行为预测

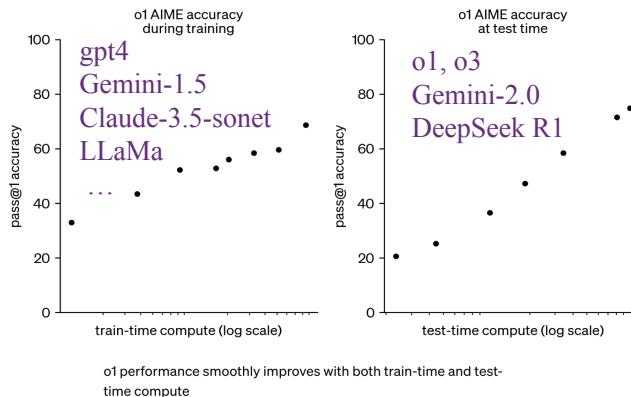
LRM新突破——DeepSeek大模型

- 2023年05月，DeepSeek公司成立，口号是探索未至之境
- 2023年11月，发布 DeepSeek LLM包括 7B 和 67B 参数版本。其中，67B 基础模型在推理、编码等任务上超越 Llama2 70B
- 2024年02月，与北京大学合作推出DeepSeek-Coder代码模型系列，参数范围从13亿到330亿，处理复杂编码
- 2024年05月，DeepSeek-V2 引入混合专家DeepSeekMoE架构和新型注意力机制MLA，引发国内大模型厂商价格战
- 2024年11月，推出 R1-Lite-Preview，在逻辑推理、数学问题解决和实时挑战等推理任务中表现出色
- 2024年12月，DeepSeek V3采用负载均衡、FP8计算等优化技术，降低训练成本和能耗，各种基准稳定前十名
- 2025年01月，DeepSeek R1采用多阶段训练方式提升推理能力，性能媲美OpenAI O1模型，训练成本为其1/3

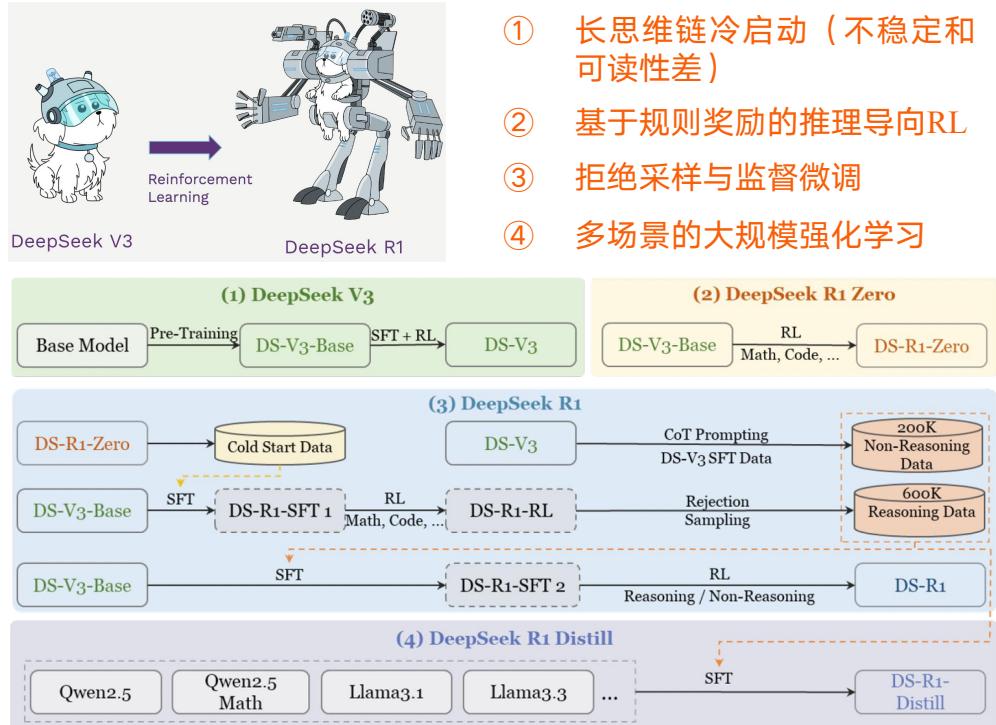


LRM新突破——DeepSeek技术亮点

- R1不是从头训练，在V3上后训练几周得到
- 深度思考训练依靠可验证问题，数学代码
- 测试时计算扩展性增强，不再需人工标注
- Aha顿悟时刻R1 zero证明大规模RL有效
- 长思维链CoT能力可以通过强化学习RL隐式激发，而不需要通过监督学习SFT显式训练



测试时计算使得思考问题的中间步骤成为可能
模型在回答之前会“推理”并探索可能的解决方案



长CoT能力
的隐式激发：
先验注入

长CoT的格式设计：总体推理流程为思考部分和总结部分

<think> reasoning </think> <answer> answer </answer>

长CoT的奖励设计：格式性奖励和正确性奖励

- 格式性奖励：模型是否把思考过程放在了<think>和</think>之中；
- 正确性奖励：模型是否在思考+总结后生成了正确的答案

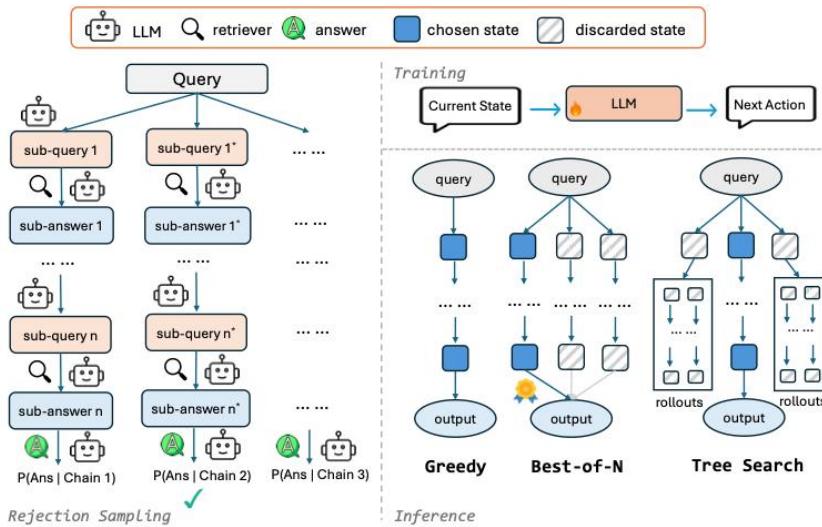
- ① 长思维链冷启动（不稳定和可读性差）
- ② 基于规则奖励的推理导向RL
- ③ 拒绝采样与监督微调
- ④ 多场景的大规模强化学习

检索链规划

CoRAG: LLM检索链规划

动态检索过程

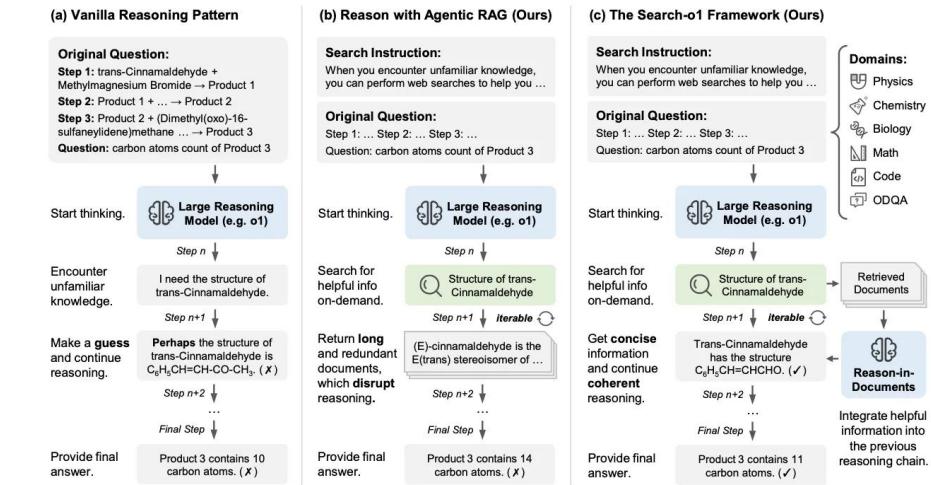
- 逐步检索信息并进行调整；
- 根据需要重新制定查询；
- 自主决定**需要多少次检索步骤



Search O1: LRM检索链规划与精炼

动态代理检索机制：LRM**自主触发外部知识检索**，动态补充知识缺口，支持多次迭代检索。

Reason-in-Documents 知识精炼模块：独立处理检索到的冗长文档，**提取关键信息并整合到推理链中**。避免直接注入原始文档导致的噪音和逻辑断裂。

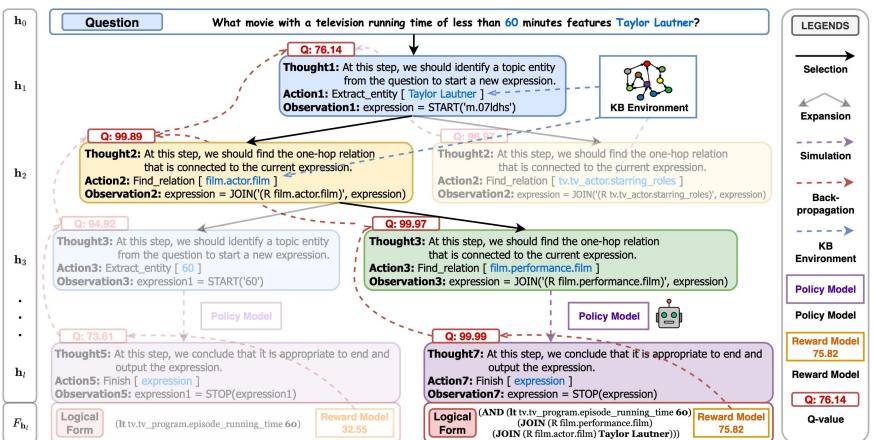
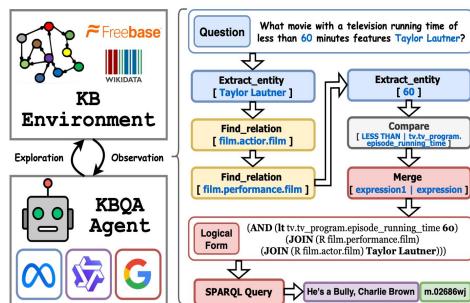


算子/实体规划

KBQA-O1: KG上的算子规划

ReAct-based 过程：通过逐步生成逻辑形式并与 KB 环境交互，提升对 KB 结构的感知能力。

KB—Based 推理：预测下一步动作，动作是KG上可执行算子（例如查询、聚合、抽取），生成候选路径。

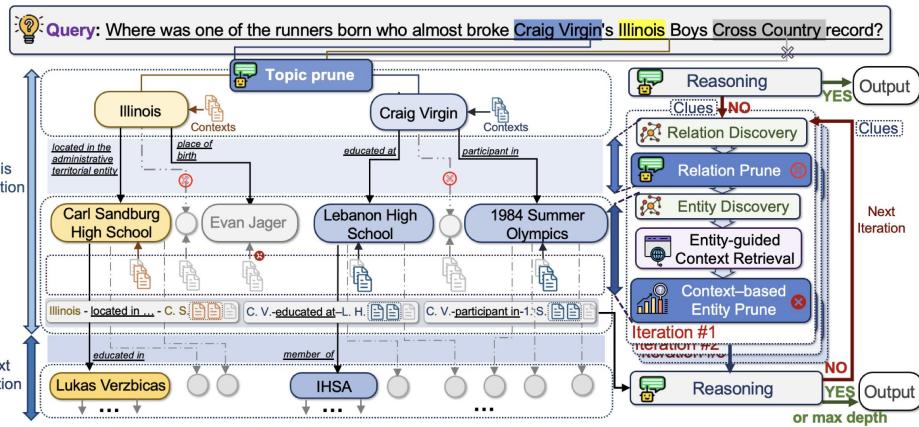


ToG 2.0: KG上的知识（实体/关系）推理

紧密耦合知识图谱与文本检索：通过KG连接文档实体，利用文档内容作为实体上下文，解决中知识碎片化和结构关系缺失的问题。

迭代式混合知识探索

- 图检索：基于 KG 的关系发现与剪枝，扩展候选实体路径。
- 上下文检索：筛选高相关实体，反向优化图检索方向。
- 交替迭代直至收集足够线索，模拟人类逐步推理过程。



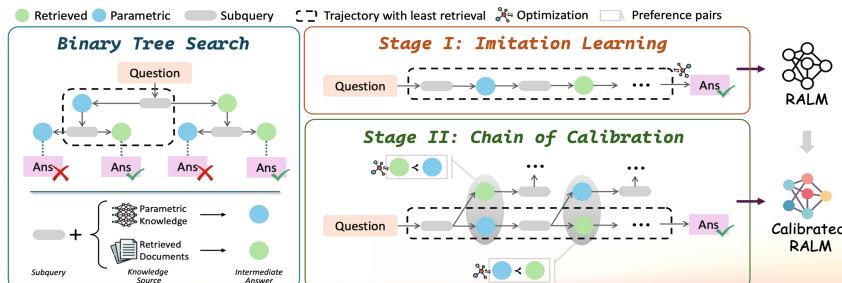
路径搜索

DeepRAG: 二叉树搜索

动态检索决策：将RAG建模为马尔可夫决策过程（MDP），通过状态转移动态决定是否检索外部知识或依赖模型内部知识。

模仿学习：让模型学会以最小化检索成本（如次数）将复杂问题分解为子查询序列。

校准链（Chain of Calibration）：通过偏好数据优化原子决策，提升模型对自身知识边界的认知。



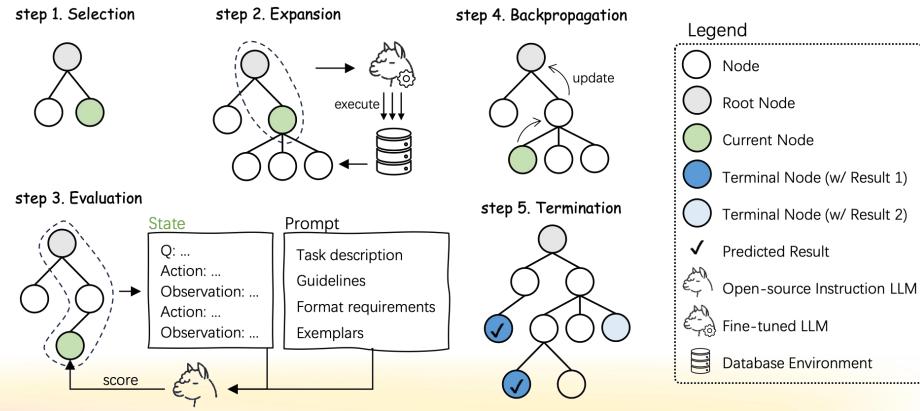
DeepRAG: Thinking to Retrieval Step by Step for Large Language Models, 2025.

MCTS-KBQA: 蒙特卡洛树搜索

MCTS 与 KBQA 结合：借助 MCTS 的选择、扩展、评估、模拟和反向传播步骤，有效探索解决方案，提升推理效率。

分步奖励机制：依据 KBQA 任务特点，设计规则提示文本，评估中间状态是否成功识别元素和解决子问题。

中间推理标注数据：运用远程监督技术，为现有的问题 - SPARQL 数据集标注中间推理过程，助力低资源场景下模型性能提升。



MCTS-KBQA: Monte Carlo Tree Search for Knowledge Base Question Answering, 2025.

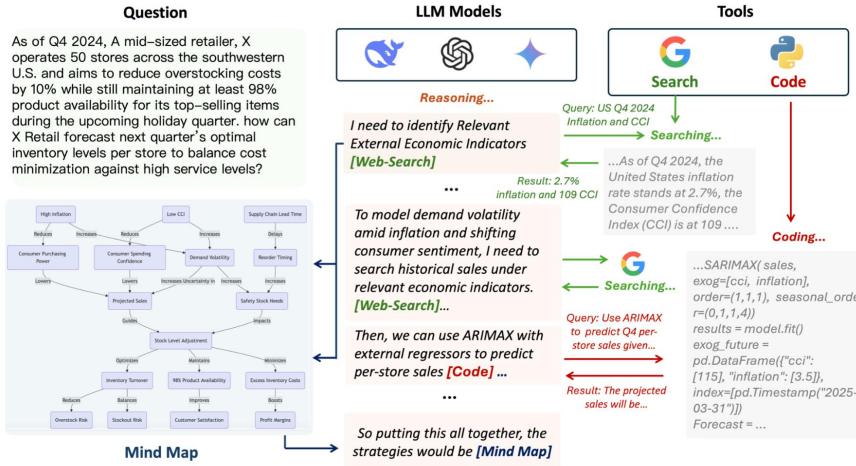
行为预测

Agentic Reasoning: LLM 特殊Token预测

动态任务委托: 通过Special Token (如[Web-Search]/[Code]) 实时触发代理，按需检索信息、执行计算或构建知识图。

结构化知识管理: Mind Map 代理构建逻辑关系图，提升复杂问题的演绎推理能力，避免传统 LLM 的逻辑断裂。

任务专业化分工: 使用专用 LLM (如代码生成、知识图构建) 处理辅助任务，减少主模型干扰，提升效率。

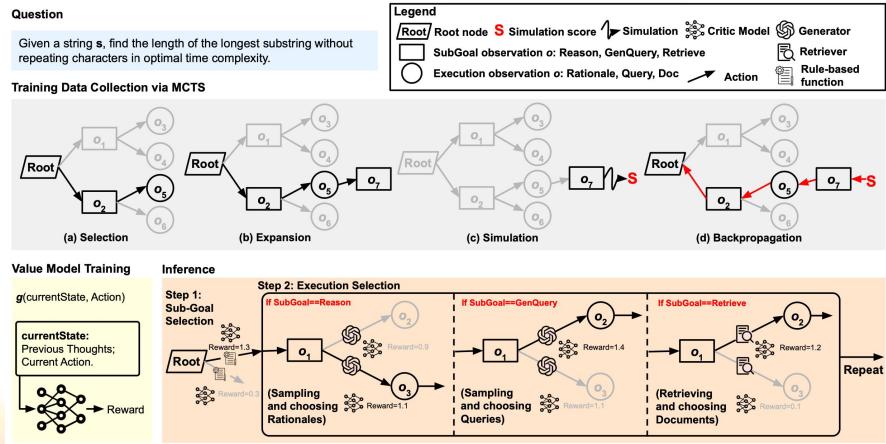


CR-Planner: 专有模型行为预测

评论家指导规划: 引入子目标评论家和执行评论家，分别指导推理、检索的子目标选择和执行步骤，动态优化问题解决路径。

MCTS数据生成: 通过 MCTS 模拟不同动作序列，收集带有长期奖励标签的训练数据，解决评论家模型训练数据稀缺问题。

检索增强与动态规划结合: 在推理过程中动态决定何时检索、如何生成查询，并通过评论家筛选相关文档，减少无关知识干扰。



如何融合KG增强LLM推理能力？

KG与LLM融合的五大技术路径： 1) Prompt工程 2) 模型微调 3) RAG 4) LRM协同 5) 知识智能体

Prompt工程

模型微调

RAG

LRM协同

知识智能体

图谱增强提示

图谱知识注入

图谱增强检索

检索链规划

图谱优化工作流

图谱推理微调

轻量化GraphRAG

算子/实体规划

图谱个性化智能体

图谱知识对齐

个性化GraphRAG

路径搜索

行为预测

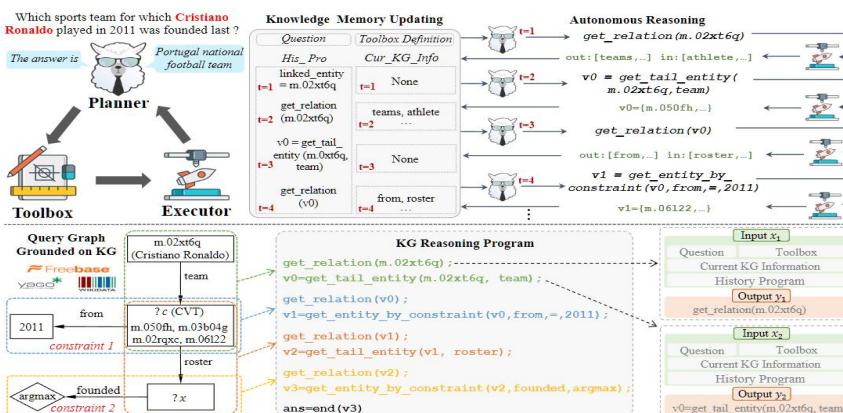
图谱优化工作流

KG-Agent: KG上复杂推理的高效智能体

结构化数据工具箱：扩展LLM对知识图谱的结构化操作能力，通过多功能工具集，处理KG数据及中间推理结果。

代码指令微调：基于KG推理数据集生成与推理链对应的程序代码，构建代码指令训练数据，使小参数LLM具备复杂推理能力。

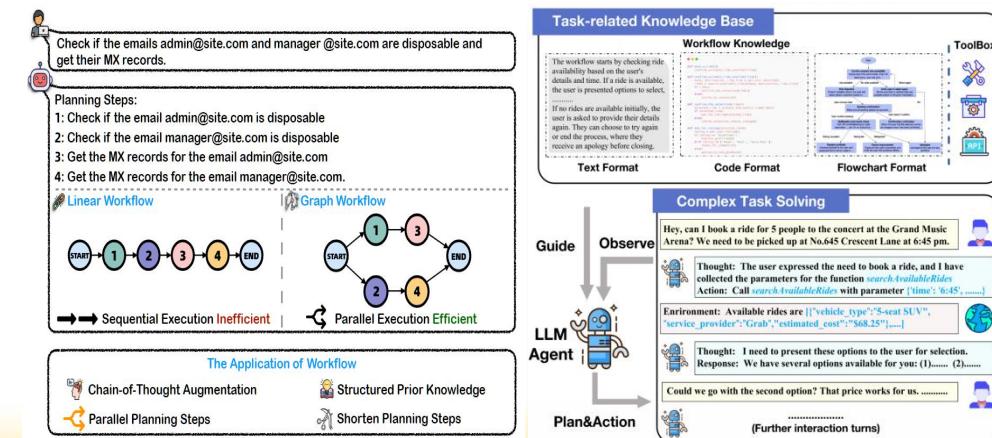
自主迭代引擎：融合工具选择机制与动态记忆更新策略，将微调后的LLM、工具集、KG执行器、知识记忆模块进行系统集成，实现自动化的KG自主推理闭环。



智能体工作流增强

工作流图结构建模增强：采用有向无环图（DAG）表征子任务关系，支持并行执行分支与复杂依赖关系建模，突破传统线性流程限制，提升复杂场景下的拓扑表达能力；

动态可验证约束机制：通过结构相似性验证（DAG比对）与执行路径可达性检测，建立闭环反馈系统，在解码阶段实时校正幻觉性规划，保障工作流逻辑可行性。



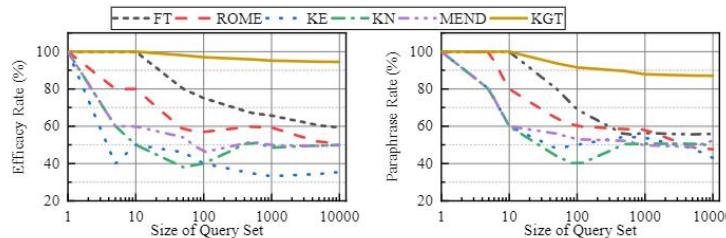
图谱个性化智能体

KGT: 提升智能体定制能力

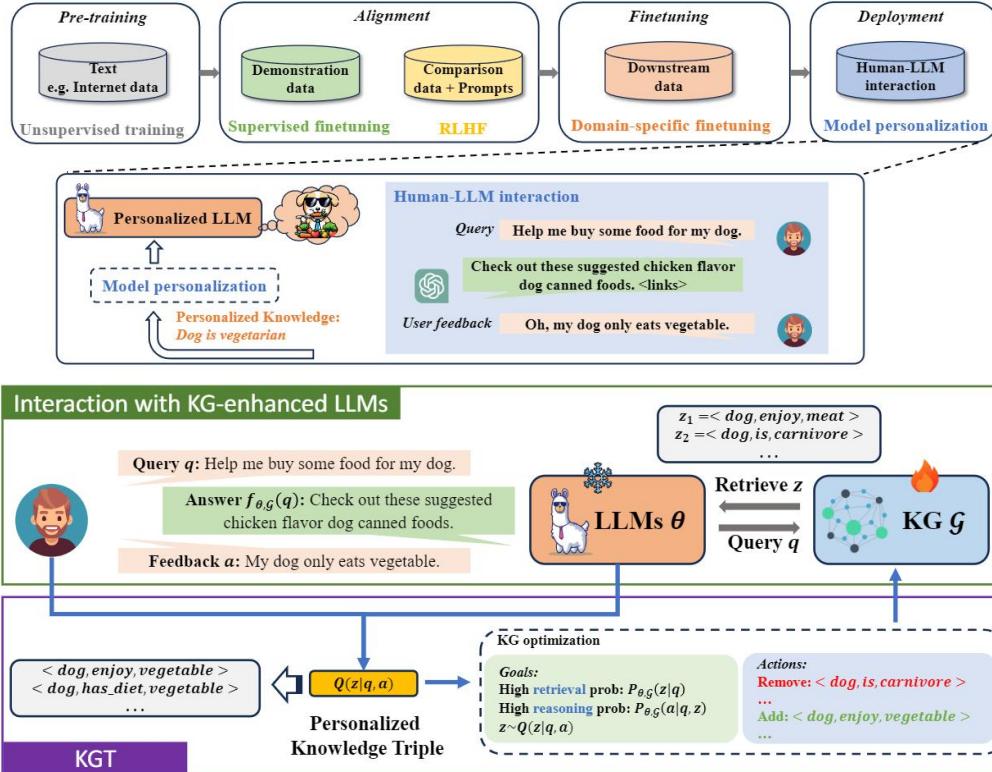
知识反馈调优：通过用户查询与反馈提取个性化知识三元组，优化知识图谱结构而非LLM参数，**实现模型个性化适配**。

双目标优化框架：基于证据下界（ELBO）设计训练目标，联合优化个性化知识检索概率与知识增强推理概率，**确保知识精准匹配与逻辑一致性**。

轻量级图谱编辑：采用启发式算法**动态增删KG三元组**，避免模型重训练，显著**提升计算效率**；调整过程保留人类可理解的语义逻辑，保障方法可解释性。



基于Llama3-8B的不同智能体在CounterFact数据集上随查询集大小变化的表现，KGT的泛化性强，计算效率更加稳定



应用与展望

KG+LLM的行业应用与趋势展望

KG + LLM的应用场景

KG+LLM 的结合，兼顾了外部知识依赖和复杂推理的需求，使得LLM更加胜任复杂的真实场景。

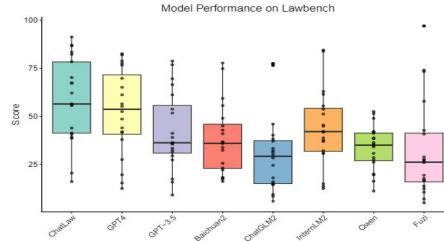
法律: Chatlaw

- 法律: 复杂推理任务+时效性条文适配

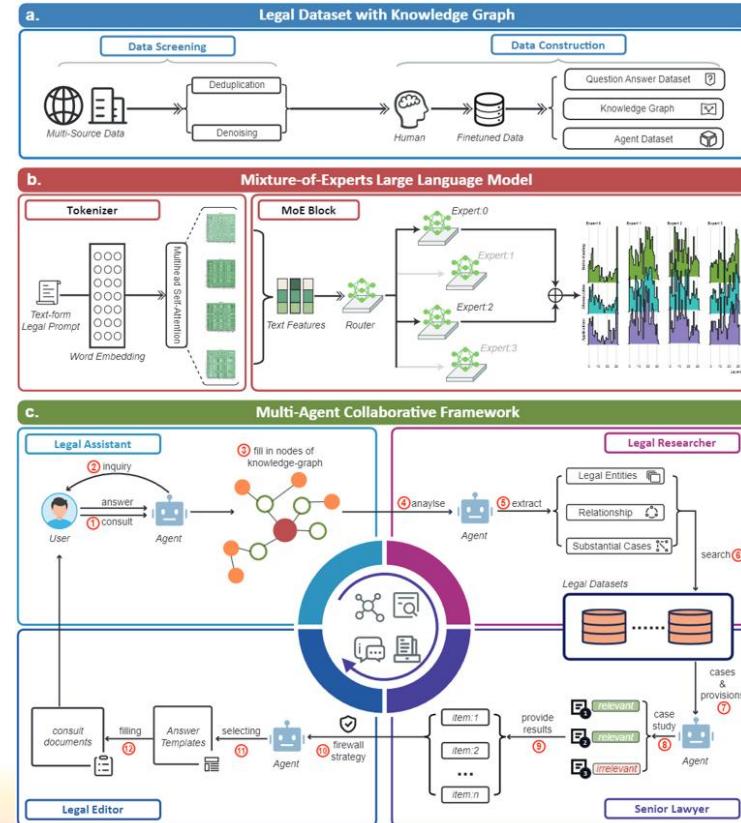
法律数据集构建：通过重复数据删除和降解以获取标准化的法律问答数据集。通过专家标注生成KG和智能代理任务数据集。

混合专家模型构建：设计MoE模型，并采用动态路由网络根据输入特征激活对应专家模块，实现罪名认定与量刑建议的精准匹配。通过对抗性样本注入与专家负载均衡约束，增强模型对非常规输入（如模糊表述、隐蔽诱导）的抗干扰能力。

多智能体协作推理：采用法律助理、研究员、资深律师、编辑员四智能体协作，模拟真实律所SOP工作流。对接裁判文书网等官方源，动态维护法律条文、典型案例与司法解释的时效性关联。



上图展示了Chatlaw在公开法律基准Lawbench上的效果，以及其他通用LLM的对比，超过了GPT-4。



KG + LLM的应用场景

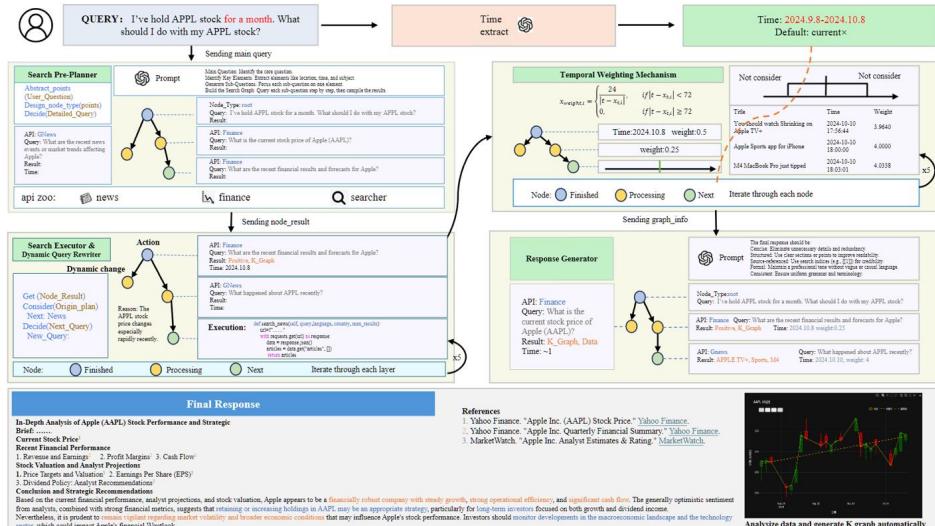
金融: FinSearch

- 金融: 复杂推理任务+高频更新的外部专业知识

动态自适应搜索机制

- 分步查询规划: 通过 LLM 将复杂金融问题分解为子查询, 构建DAG, 明确逻辑依赖关系。
- 实时查询优化: 在搜索执行过程中, 基于中间结果动态调整后续子查询, 提升市场动态响应能力。

时间敏感加权机制: 引入 72 小时时间窗口的线性衰减函数, 优先处理近期信息(如新闻、股价波动), 强化时间相关性。



Method	Accuracy (%)					Time (s/answer)				
	GPT-4o	Llama3.1-405B	Claude3.5-Sonnet	Deepseek	Gemini-1.5-Flash	GPT-4o	Llama3.1-405B	Claude3.5-Sonnet	Deepseek	Gemini-1.5-Flash
Baseline	36.13 ± 1.22	38.13 ± 1.27	38.60 ± 1.28	34.07 ± 1.21	35.47 ± 1.22	3.87 ± 0.15	4.96 ± 0.25	6.66 ± 0.21	14.50 ± 0.27	5.04 ± 0.16
SearchAgent	46.33 ± 1.30	43.80 ± 1.24	41.87 ± 1.29	44.27 ± 1.26	42.33 ± 1.28	1.58 ± 0.06	1.61 ± 0.07	1.54 ± 0.06	1.32 ± 0.04	1.58 ± 0.04
MindSearch	52.40 ± 1.33	53.07 ± 1.34	53.60 ± 1.28	49.73 ± 1.32	51.53 ± 1.29	19.09 ± 0.39	14.82 ± 0.45	17.93 ± 0.39	27.01 ± 0.58	20.14 ± 0.43
Perplexity Pro	60.27 ± 1.26	61.47 ± 1.28	56.67 ± 1.24	-	-	6.12 ± 0.26	3.94 ± 0.15	5.85 ± 0.22	-	-
Ours	76.20 ± 1.12	75.53 ± 1.08	78.27 ± 1.07	72.33 ± 1.15	74.87 ± 1.08	16.03 ± 0.43	14.55 ± 0.47	18.15 ± 0.35	29.31 ± 0.70	17.74 ± 0.53

上图展示了不同智能体方法在金融基准FinSearchBench-24上的性能和计算效率的对比, 其中本文的方法取得了更高的准确率与更低的计算开销

KG + LLM的应用场景

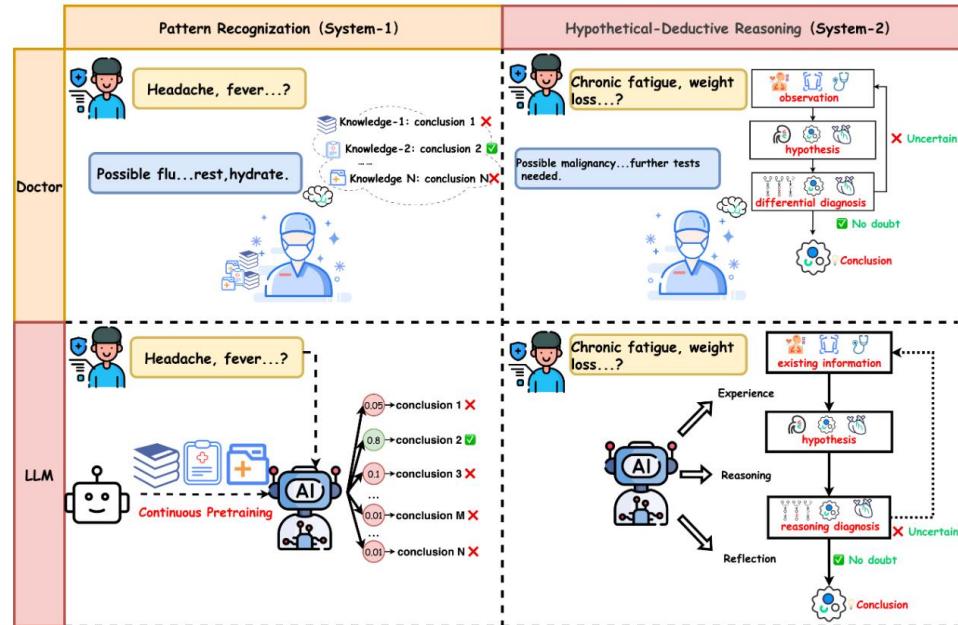
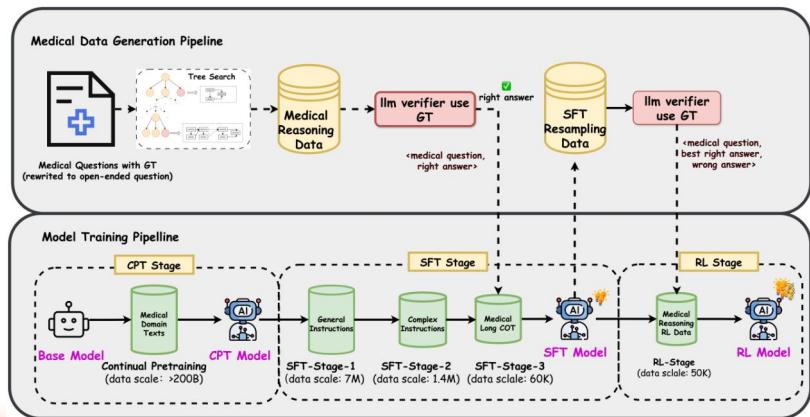
医疗: Citrus

- 医疗: 复杂推理任务+强领域知识+低幻觉容忍

模拟专家认知路径: 提出结合“假设 - 演绎推理”和“模式识别”的双专家推理框架, **模仿医生的临床决策过程**。

双专家推理机制:

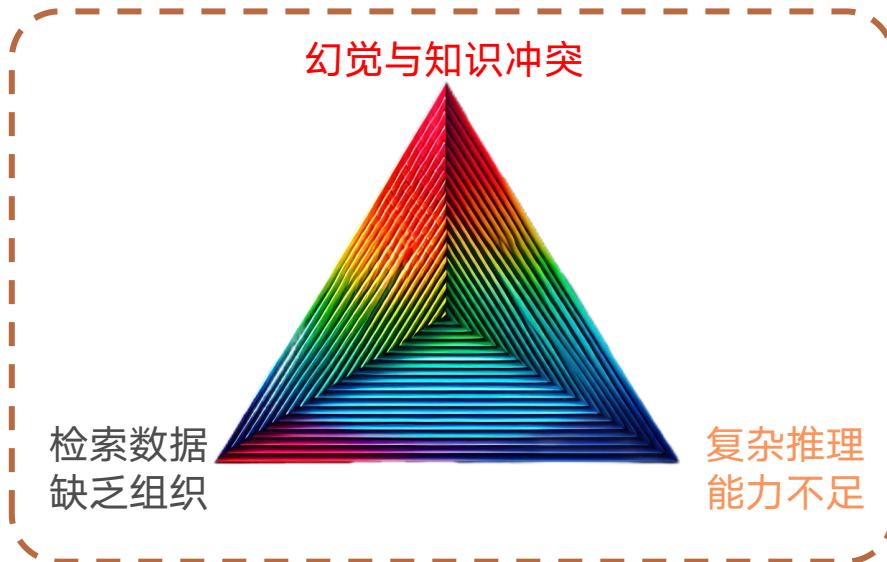
- 推理专家: 生成假设 - 演绎推理链。
- 反思专家: 基于真实答案验证推理逻辑, **过滤无效步骤**。



通过SFT和RL的训练, LLMs 表现出与医学专家相似的临床决策路径

KG + LLM的总结与展望

总结：KG+LLM致力于解决的三个关键问题



进一步开放问题：

趋势：KG与LLM的深度融合能否

构建下一代可信智能体系统？

技术：KG-Agent融合LRM的挑战？

场景：在高要求场景能否进行实现
自适应协同与可靠决策？

OpenKG 旨在促进以中文为核心的知识图谱数据的开放、互联与众包，以及知识图谱工具、模型和平台的开源开放

- 实践总结：

开放普及、交叉共融、共享推广、创新发展

- 未来展望：

拓展应用场景、加强技术研发、促进生态建设、提升社区活力



构建大模型时代下全球领先的知识图谱开源生态，
为各行业提供智能化知识服务，促进知识共享与增值

谢谢观看



演讲人：王昊奋 | 同济大学 特聘研究员

DataFunSummit 2025